

Informe Tecnico

2025-04-11

Requerimientos de RStudio

Para la elaboración del presente informe se reutilizarán técnicas de manipulación de datos previamente desarrolladas y documentadas en el repositorio del equipo de trabajo. Esto permitirá agilizar el procesamiento y asegurar la consistencia metodológica con informes anteriores.

Los bloques de código iniciales permitirán instalar y cargar las librerías necesarias para la elaboración del informe. Estas librerías permiten la manipulación, visualización y análisis estadístico de los datos en el entorno de trabajo RStudio. El código contempla tanto la instalación (en caso de que no estén previamente disponibles) como la carga de los paquetes requeridos para garantizar la reproducibilidad del análisis.

```
# setup
knitr::opts_chunk$set(echo = TRUE, warning = FALSE, message=FALSE)

# Lista de librerías
packages <- c("readxl", "dplyr", "tidyr", "data.table", "stringr")

# Instalación de librerías
installed_packages <- packages %in% rownames(installed.packages())
if (any(installed_packages == FALSE)) {install.packages(packages[!installed_packages])}

# Carga de librerías
invisible(lapply(packages, library, character.only = TRUE))
```

Tratamiento de datos agrupados de encuestas

En una primera etapa, se procede a la carga de los datos generales correspondientes a las encuestas realizadas por barrio, provincia y región. Al analizar el conjunto de datos original, se detectan inconsistencias que requieren un proceso de limpieza previo al análisis estadístico.

Entre las principales irregularidades se identifican:

- Campos vacíos resultantes de celdas combinadas en el archivo original (formato Excel).
- Registros duplicados o múltiples encuestas asociadas a un mismo barrio.
- Filas sin encuestas registradas (valores NA).

El proceso de limpieza aplicado consistirá en completar los campos faltantes mediante propagación de valores válidos y en la eliminación de aquellas filas que no contengan datos relevantes para el análisis.

Al continuar con la exploración de los datos, se identifica la existencia de barrios registrados en múltiples filas, cada una con un número distinto de encuestas asociadas. Esta duplicación puede deberse a errores en el archivo original o simplemente tratarse de valores desagrupados. Con el objetivo de facilitar el análisis posterior y evitar distorsiones en los resultados, se optó por consolidar estos registros. Para ello, se agruparon las observaciones por barrio, sumando la cantidad total de encuestas correspondientes a cada uno. Posteriormente, se verificará la consistencia del procedimiento mediante controles cruzados con los datos originales.

```
# Exploración inicial de datos originales
bu <- read_excel(path = "./Barrios_Usuarios.xlsx") %>% data.frame()
bu$BARRIO = str_to_title(bu$BARRIO)
```

```

bu$PROVINCIA = str_to_title(bu$PROVINCIA)
bu_original <- bu

# Limpieza de datos
bu <- bu %>%
  fill(REGIÓN, PROVINCIA, BARRIO, .direction = "down") %>%
  drop_na(ENCUESTAS) %>%
  arrange(desc(ENCUESTAS))

# Dataframe de duplicados
bu_duplicados <- bu %>%
  group_by(BARRIO) %>%
  filter(n() > 1) %>%
  arrange(desc(BARRIO))

# Agrupación de datos y suma de encuestas
bu <- bu %>%
  group_by(REGIÓN, PROVINCIA, BARRIO) %>%
  summarise("TOTAL ENCUESTAS" = sum(ENCUESTAS)) %>%
  arrange(desc(`TOTAL ENCUESTAS`))

# Muestra de resultados
#bu_original
#bu_duplicados
#bu

```

Analisis de encuestas

En esta sección se analizarán los resultados obtenidos a partir de encuestas realizadas en distintos barrios del país, categorizados según sus respectivas provincias y regiones. Asimismo, se detalla la cantidad total de encuestas efectuadas en cada barrio, lo que permite dimensionar el alcance de la recolección de datos.

Distribución de Encuestas por región

En una primera instancia, se observa la distribución de encuestas por región. Este análisis preliminar permite evaluar la representatividad de la muestra en relación con la población objetivo. Se destaca que la región del Noroeste Argentino concentra una proporción significativamente mayor de encuestas en comparación con el resto del país, lo cual constituye una posible fuente de sesgo en los resultados generales y deberá ser considerado en el análisis posterior.

Dentro de la región del Noroeste Argentino (NOA), se identificó al barrio Bosco II con un número significativamente elevado de encuestas en comparación con otros barrios de la misma región y en otras regiones. Esta situación amerita una revisión detallada para verificar la validez de los datos y descartar posibles errores de carga o duplicación.

Se realizará un análisis específico sobre este caso para asegurar la integridad de la información antes de su inclusión en el análisis estadístico global.

```

# Agrupación de datos y suma de encuestas
bu_region <- bu %>%
  group_by(REGIÓN) %>%
  summarise("TOTAL ENCUESTAS" = sum(`TOTAL ENCUESTAS`)) %>%
  arrange(desc(`TOTAL ENCUESTAS`))

# Muestra de resultados
bu_region

```

```
## # A tibble: 7 x 2
##   REGIÓN    `TOTAL ENCUESTAS`
##   <chr>          <dbl>
## 1 NOA              1296
## 2 PBA              292
## 3 CABA            235
## 4 NEA              175
## 5 CENTRO          126
## 6 PATAGONIA       122
## 7 CUYO             90
```

```
bu %>% filter(REGIÓN == "NOA")
```

```
## # A tibble: 3 x 4
## # Groups:   REGIÓN, PROVINCIA [3]
##   REGIÓN PROVINCIA BARRIO    `TOTAL ENCUESTAS`
##   <chr>   <chr>    <chr>          <dbl>
## 1 NOA     Santiago  Bosco Ii          1200
## 2 NOA     Jujuy     28 De Septiembre    56
## 3 NOA     Tucumán   11 De Enero         40
```

Distribución de Encuestas por provincia

El análisis a nivel provincial revela una distribución heterogénea en la cantidad de encuestas relevadas. Por ejemplo, la provincia del Chaco cuenta con solo 36 encuestas, mientras que la provincia de Buenos Aires presenta 292. Tal disparidad puede afectar la representatividad de los resultados.

El caso de Santiago del Estero, particularmente el barrio Bosco II, ya fue abordado por su impacto en la concentración de datos. Esta variabilidad refuerza la necesidad de interpretar los resultados con cautela, reconociendo la posibilidad de sesgos derivados de un muestreo no equilibrado entre regiones y provincias.

```
# Agrupación de datos y suma de encuestas
bu_provincia <- bu %>%
  group_by(PROVINCIA) %>%
  summarise("TOTAL ENCUESTAS" = sum(`TOTAL ENCUESTAS`)) %>%
  arrange(desc(`TOTAL ENCUESTAS`))
```

```
# Muestra de resultados
bu_provincia
```

```
## # A tibble: 16 x 2
##   PROVINCIA `TOTAL ENCUESTAS`
##   <chr>          <dbl>
## 1 Santiago      1200
## 2 Bsas          292
## 3 Caba          235
## 4 Río Negro     70
## 5 Mendoza       60
## 6 Córdoba       59
## 7 Jujuy         56
## 8 Santa Cruz    52
## 9 Corrientes    51
## 10 Misiones     48
## 11 Formosa      40
## 12 Santa Fe     40
## 13 Tucumán      40
## 14 Chaco        36
```

```
## 15 La Rioja          30
## 16 Entre Ríos        27
```

Distribución de Encuestas por barrio

Dada la alta concentración de encuestas en el barrio Bosco II, se observa que la media de encuestas por barrio no es un indicador adecuado para reflejar la distribución central de los datos. La presencia de valores atípicos puede distorsionar el cálculo de la media, haciéndola menos representativa del conjunto general. En este contexto, se opta por utilizar la mediana como medida central, ya que esta estadística es más robusta frente a los sesgos introducidos por la disparidad en la cantidad de encuestas entre barrios. Es decir, que analizaremos aproximadamente 51 encuestas por barrio.

```
# Agrupación de datos y suma de encuestas
bu_barrio <- bu %>%
  group_by(BARRIO) %>%
  summarise("TOTAL ENCUESTAS" = sum(`TOTAL ENCUESTAS`)) %>%
  arrange(desc(`TOTAL ENCUESTAS`))

# Agrupación de datos y suma de encuestas sin total de encuestas en barrios mayor o igual a 1200
bu_barrio_filtrado <- bu %>%
  filter(`TOTAL ENCUESTAS` < 1200) %>%
  group_by(BARRIO) %>%
  summarise("TOTAL ENCUESTAS" = sum(`TOTAL ENCUESTAS`)) %>%
  arrange(desc(`TOTAL ENCUESTAS`))

# Muestra de resultados
bu_barrio %>% head(10)
```

```
## # A tibble: 10 x 2
##   BARRIO          `TOTAL ENCUESTAS`
##   <chr>                <dbl>
## 1 Bosco Ii           1200
## 2 Villa 31             107
## 3 Los Alamos           94
## 4 Villa 20             88
## 5 Fiske Menuco         70
## 6 Altos De San Lorenzo 60
## 7 Constitución         60
## 8 Alberdi              59
## 9 28 De Septiembre     56
## 10 Madres A La Lucha    52
```

```
# Muestra de medidas características sobre la distribución de encuestas en barrios
bu_barrio %>% select(`TOTAL ENCUESTAS`) %>% summary()
```

```
## TOTAL ENCUESTAS
## Min.   : 15.0
## 1st Qu.: 40.0
## Median : 51.0
## Mean   : 101.6
## 3rd Qu.: 60.0
## Max.   :1200.0

# Muestra de resultados
#bu_barrio_filtrado

# Muestra de medidas características sobre la distribución de encuestas en barrios según filtro anterior
```

```
#bu_barrio_filtrado %>% select(`TOTAL ENCUESTAS`) %>% summary()
```

Tratamiento de datos de encuesta

Se analizarán las respuestas sobre las encuestas realizadas que han sido documentadas en el archivo “Datos_LP”. Esta información originalmente no posee las características de datos ordenados según las librerías que se pretenden utilizar. Para ello, se tratarán los datos para lograr una estructura “tidy”, esto es: - Cada columna será una variable, es decir, una pregunta de la encuesta. - Cada fila un resultado de encuesta dado por grupo familia. - Cada valor será el la respuesta dada a una pregunta por el grupo familiar.

Con este objetivo entonces se realizan las siguientes transformaciones: - Unificación de los títulos multinivel (Sección, referencia y pregunta) en el archivo. - Identificación parcial de cada pregunta y su respuesta asociada (para una posterior verificación de consistencia en los datos)

En esta sección, se observa que la cantidad de preguntas asociadas a cada tema varía considerablemente. Por ejemplo, se encuentran solo 2 preguntas relacionadas con el hacinamiento, en contraste con las 26 preguntas dirigidas al tema de materiales. Esta disparidad en la distribución de las preguntas podría influir en los resultados del análisis, ya que la representatividad de los temas tratados podría no estar equilibrada.

Es recomendable considerar este desequilibrio al interpretar las respuestas, ya que un mayor número de preguntas puede generar una mayor influencia en la percepción sobre ciertos temas.

```
# Analisis de columnas/variables de datos de encuestas por encabezados multiple
dh <- read_excel(path = "./Datos_LP.xlsx", n_max = 3, col_names = FALSE)
dh <- dh %>% transpose() %>% fill(V1, V2, V3, .direction = "down")
colnames(dh) <- c("SECCIONES", "REFERENCIA", "PREGUNTA")
dh <- dh[-1:-3,]
dh <- dh %>% group_by(PREGUNTA) %>% mutate(ID = row_number(PREGUNTA))
dh$ID <- paste(dh$REFERENCIA, dh$ID, sep = "_")
dh$ID <- paste("id", dh$ID, sep = "_")
```

```
# Cantidad de preguntas por sección
dh_secciones <- dh %>%
  group_by(SECCIONES) %>%
  summarize("TOTAL PREGUNTAS" = n()) %>%
  arrange(desc(`TOTAL PREGUNTAS`))
```

```
# Cantidad preguntas con más de una opción de respuesta
dh_multiples <- dh %>%
  group_by(PREGUNTA) %>%
  summarize("TOTAL OPCIONES DE RESPUESTAS" = n()) %>%
  filter(`TOTAL OPCIONES DE RESPUESTAS` > 1) %>%
  arrange(desc(`TOTAL OPCIONES DE RESPUESTAS`))
```

```
# Exploración inicial de datos originales
df <- read_excel(path = "./Datos_LP.xlsx", skip = 3, col_names = col_names) %>% data.frame() %>% arrange()
df$BARRIO = str_to_title(df$BARRIO)
df$PROVINCIA = str_to_title(df$PROVINCIA)
df_original <- df
```

```
# Muestra de datos
#df_original
#dh_secciones
#dh_multiples
```

Verificación de suma de encuestas en barrios

Se observa que la suma de los datos en general parece correcta. Sólo algunos casos no coinciden y habrá que tener esto en cuenta en el momento de análisis por region y provincia o si se hicieran inferencias sobre la población.

```
# Tratamiento de dataframes
df_barrio <- df_original %>%
  group_by(BARRIO) %>%
  summarise("TOTAL ENCUESTAS" = n()) %>%
  arrange(desc(`TOTAL ENCUESTAS`))

# Muestra de resultados
full_join(x = df_barrio, y = bu_barrio, by = "BARRIO")
```

```
## # A tibble: 23 x 3
##   BARRIO                `TOTAL ENCUESTAS.x` `TOTAL ENCUESTAS.y`
##   <chr>                  <int>          <dbl>
## 1 Villa Cabello (Chacra 159)          109            48
## 2 Villa 31                        107           107
## 3 Los Alamos                       94            94
## 4 Villa 20                         88            88
## 5 Fiske Menuco                     70            70
## 6 Altos De San Lorenzo              60            60
## 7 Constitución                   60            60
## 8 28 De Septiembre                56            56
## 9 Alberdi                         52            59
## 10 Madres A La Lucha               52            52
## # i 13 more rows
```

Selección de variables de estudio para descripciones gráficas

Se analizará la información obtenida del Relevamiento de Condiciones Habitacionales en particular sobre algunos puntos de interés con el objetivo de poder generar impacto en la sociedad sobre las condiciones en las se encontraban las familias en distintas villas en el año 2022, para poder generar conciencia social y, más importante aún, posibilitar la mejora de las condiciones de vida. Eventualmente, dado el soporte del Oberatorio Villero, esta información será nuevamente relevada y se podrá determinar si las acciones tomadas mejoraron las condiciones de vida generales de las familias involucradas.

Dado a que la información recolectada puede no ser completamente correcta desde un punto de vista técnico estadístico, las conclusiones obtenidas se complementarán con los contenidos teóricos provistos por la cátedra de Probabilidad y Estadística de la Facultad de Ciencias Exactas, Ingeniería y Agrimensura.

Variable categórica medida en escala nominal

Se comenzará el análisis estudiando la situación en la que los habitantes se encuentran en sus domicilios. Esto ayudará a poner en contexto e intentar entender sobre responsabilidades por problemas en los domicilios.

- Sección: 4 Propiedad
- Referencia: 4.3
- Pregunta: “El lugar que habitan actualmente es:”
- Respuestas:
- “Alquilado”
- “Ocupado/Tomado”
- “Otro”
- “Prestado”

- “Propio con algún comprobante de tenencia”
- “Propio sin títulos”

```
# Muestra Seccion y pregunta del dataframe de encuestas
dh %>% filter(grepl("4.3", REFERENCIA))
```

```
## # A tibble: 2 x 4
## # Groups:   PREGUNTA [2]
##   SECCIONES      REFERENCIA PREGUNTA      ID
##   <chr>         <chr>      <chr>      <chr>
## 1 Sección 4: Propiedad 4.3      El lugar que habitan actualmente es: id_4.3_1
## 2 Sección 4: Propiedad 4.4.3    ¿Cuánto aumentó en el último año? id_4.4.3~
```

```
# Muestra exploratoria de respuestas del dataframe de encuestas
df %>% group_by(id_4.3_1) %>% summarise("TOTAL" = n())
```

```
## # A tibble: 6 x 2
##   id_4.3_1      TOTAL
##   <chr>      <int>
## 1 Alquilado      122
## 2 Ocupado/Tomado    72
## 3 Otro           27
## 4 Prestado        83
## 5 Propio con algún comprobante de tenencia 344
## 6 Propio sin títulos 574
```

```
# Selección de datos
df_propiedad <- df %>% select(ORDEN, PROVINCIA, BARRIO, id_4.3_1)
```

```
# Tratamiento de datos
df_propiedad <- df_propiedad %>%
  group_by(PROVINCIA, BARRIO, id_4.3_1) %>%
  tally() %>%
  pivot_wider(names_from = id_4.3_1, values_from = n)
```

```
# Muestra de datos
df_propiedad
```

```
## # A tibble: 23 x 8
## # Groups:   PROVINCIA, BARRIO [23]
##   PROVINCIA      BARRIO      Alquilado Prestado Propio con algún compr-1
##   <chr>      <chr>      <int>      <int>      <int>
## 1 Buenos Aires Altos De San Lorenzo      1      2      22
## 2 Buenos Aires Las Dalias      11      5      17
## 3 Buenos Aires Las Quintas      11      6      13
## 4 Buenos Aires Los Alamos       4      2      13
## 5 Buenos Aires Villa Cordobita    NA      4       9
## 6 Caba      Villa 20      18      5      32
## 7 Caba      Villa 31      35      2       7
## 8 Caba      Zavaleta       9      1       7
## 9 Chaco      Chacra 136     NA     NA      32
## 10 Corrientes Río Paraná     NA     NA      19
## # i 13 more rows
## # i abbreviated name: 1: `Propio con algún comprobante de tenencia`
## # i 3 more variables: `Propio sin títulos` <int>, `Ocupado/Tomado` <int>,
## # Otro <int>
```

```
# Muestra de medidas características
```

```
df_propiedad[3:7] %>%  
  summary()
```

```
##      Alquilado      Prestado      Propio con algún comprobante de tenencia  
## Min.   : 1.000    Min.   : 1.000    Min.   : 1.00  
## 1st Qu.: 2.000    1st Qu.: 2.000    1st Qu.: 7.25  
## Median : 4.000    Median : 4.000    Median :13.00  
## Mean   : 7.625    Mean   : 4.611    Mean   :15.64  
## 3rd Qu.: 9.500    3rd Qu.: 5.000    3rd Qu.:18.75  
## Max.   :35.000    Max.   :15.000    Max.   :47.00  
## NA's   :7        NA's   :5        NA's   :1  
## Propio sin títulos Ocupado/Tomado  
## Min.   : 4.00     Min.   : 1.000  
## 1st Qu.:15.00     1st Qu.: 1.000  
## Median :20.00     Median : 2.000  
## Mean   :24.96     Mean   : 5.538  
## 3rd Qu.:33.50     3rd Qu.: 3.000  
## Max.   :74.00     Max.   :41.000  
##      NA's      :10
```

Variable categórica medida en escala ordinal

COMPLETAR POR QUÉ ELEGIMOS ESTO.

- Sección: 11 Ambiente
- Referencia: 11.9.2
- Pregunta: “¿Con qué frecuencia el Municipio recolecta los residuos en sus inmediaciones?”
- Respuestas: “Al menos 5 veces a la semana” “Entre 2 y 4 veces a la semana” “No hay servicio de recolección municipal” “Una vez a la semana”

```
# Muestra Seccion y pregunta del dataframe de encuestas
```

```
dh %>% filter(grepl("11.9.2", REFERENCIA))
```

```
## # A tibble: 1 x 4  
## # Groups:   PREGUNTA [1]  
##   SECCIONES      REFERENCIA PREGUNTA      ID  
##   <chr>         <chr>      <chr>      <chr>  
## 1 Sección 11: Ambiente 11.9.2    ¿Con qué frecuencia el Municipio recole~ id_1~
```

```
# Muestra exploratoria de respuestas del dataframe de encuestas
```

```
df %>% group_by(id_11.9.2_1) %>% summarise("TOTAL" = n())
```

```
## # A tibble: 4 x 2  
##   id_11.9.2_1      TOTAL  
##   <chr>         <int>  
## 1 Al menos 5 veces a la semana      324  
## 2 Entre 2 y 4 veces a la semana     505  
## 3 No hay servicio de recolección municipal    304  
## 4 Una vez a la semana                89
```

```
# Selección de datos
```

```
df_recolección <- df %>% select(ORDEN, PROVINCIA, BARRIO, id_11.9.2_1)
```

```
# Tratamiento de datos
```

```
df_recolección <- df_recolección %>%  
  group_by(PROVINCIA, BARRIO, id_11.9.2_1) %>%
```



```

tally() %>%
pivot_wider(names_from = id_11.9.2_1, values_from = n)

# Muestra de datos
df_recolección

## # A tibble: 23 x 6
## # Groups:   PROVINCIA, BARRIO [23]
##   PROVINCIA   BARRIO Al menos 5 veces a la semana Entre 2 y 4 veces a la semana
##   <chr>       <chr>          <int>          <int>
## 1 Buenos Aires Altos De San Lore~           3           14
## 2 Buenos Aires Las Dalias                1           47
## 3 Buenos Aires Las Quintas              22           23
## 4 Buenos Aires Los Alamos                NA           73
## 5 Buenos Aires Villa Cordobita           NA           15
## 6 Caba         Villa 20                 70           15
## 7 Caba         Villa 31                 76           28
## 8 Caba         Zavaleta                 27            1
## 9 Chaco        Chacra 136                4           27
## 10 Corrientes Río Paraná                 16            2
## # i 13 more rows
## # i abbreviated names: 1: `Al menos 5 veces a la semana`,
## #   2: `Entre 2 y 4 veces a la semana`
## # i 2 more variables: `No hay servicio de recolección municipal` <int>,
## #   `Una vez a la semana` <int>

# Muestra de medidas características
df_recolección[3:6] %>%
summary()

## Al menos 5 veces a la semana Entre 2 y 4 veces a la semana
## Min.   : 1.0           Min.   : 1.00
## 1st Qu.: 2.0           1st Qu.:10.00
## Median :14.0           Median :18.00
## Mean   :21.6           Mean   :24.05
## 3rd Qu.:24.5           3rd Qu.:37.00
## Max.   :76.0           Max.   :73.00
## NA's   :8             NA's   :2
## No hay servicio de recolección municipal Una vez a la semana
## Min.   : 1.00           Min.   : 1.000
## 1st Qu.: 3.00           1st Qu.: 1.750
## Median : 7.00           Median : 2.000
## Mean   :14.48           Mean   : 5.562
## 3rd Qu.:26.00           3rd Qu.: 8.000
## Max.   :52.00           Max.   :19.000
## NA's   :2             NA's   :7

```

Variable categórica de respuesta múltiple

Se propone analizar la presencia de plagas en la vivienda y sus alrededores. COMPETAR CON MOTIVOS.

- Sección: 10 Servicios barriales
- Referencia: 10.6.2
- Pregunta: “¿Cuáles plagas?”
- Respuestas: “Cucarachas” “Mosquitos” “Ratas”

```

# Muestra Seccion y pregunta del dataframe de encuestas
dh %>% filter(grepl("10.6.2", REFERENCIA))

## # A tibble: 3 x 4
## # Groups:   PREGUNTA [1]
##   SECCIONES                REFERENCIA PREGUNTA          ID
##   <chr>                  <chr>      <chr>          <chr>
## 1 Sección 10: Servicios barriales 10.6.2    ¿Cuáles plagas? id_10.6.2_1
## 2 Sección 10: Servicios barriales 10.6.2    ¿Cuáles plagas? id_10.6.2_2
## 3 Sección 10: Servicios barriales 10.6.2    ¿Cuáles plagas? id_10.6.2_3

# Muestra exploratoria de respuestas del dataframe de encuestas
df %>% group_by(id_10.6.2_1, id_10.6.2_2, id_10.6.2_3) %>% summarise("TOTAL" = n())

## # A tibble: 8 x 4
## # Groups:   id_10.6.2_1, id_10.6.2_2 [4]
##   id_10.6.2_1 id_10.6.2_2 id_10.6.2_3 TOTAL
##   <chr>      <chr>      <chr>      <int>
## 1 Cucarachas Mosquitos Ratas        268
## 2 Cucarachas Mosquitos <NA>         88
## 3 Cucarachas <NA>      Ratas        44
## 4 Cucarachas <NA>      <NA>         57
## 5 <NA>        Mosquitos Ratas        97
## 6 <NA>        Mosquitos <NA>       126
## 7 <NA>        <NA>      Ratas       159
## 8 <NA>        <NA>      <NA>       383

# Selección de datos
df_plagas <- df %>%
  select(ORDEN, PROVINCIA, BARRIO, id_10.6.2_1, id_10.6.2_2, id_10.6.2_3)

# Muestra de datos
#df_plagas

```

Variable cuantitativa discreta

COMPETAR CON MOTIVOS.

- Sección:
- Referencia:
- Pregunta:
- Respuestas:

```

# Muestra Seccion y pregunta del dataframe de encuestas
#dh %>% filter(grepl("XXXXX", REFERENCIA))

# Muestra exploratoria de respuestas del dataframe de encuestas
#df %>% group_by(XXXXX, XXXXX, XXXXX) %>% summarise("TOTAL" = n())

# Selección de datos
#df_aux <- df %>%
#  select(ORDEN, PROVINCIA, BARRIO, XXXXX)

# Tratamiento de datos
#df_aux <- df_aux %>%
#  group_by(PROVINCIA, BARRIO, XXXXX)

```

```
# Muestra de datos
#df_aux
```

```
# Muestra de medidas características
#df_aux %>%
# summary()
```

Variable cuantitativa continua

COMPETAR CON MOTIVOS.

- Sección: 4 Propiedad
- Referencia: 4.4.2
- Pregunta: “¿Cuál es el costo actual del mismo?”
- Respuestas:

```
# Muestra Sección y pregunta del dataframe de encuestas
dh %>% filter(grepl("4.4.2", REFERENCIA))
```

```
## # A tibble: 1 x 4
## # Groups:   PREGUNTA [1]
##   SECCIONES          REFERENCIA PREGUNTA          ID
##   <chr>            <chr>      <chr>          <chr>
## 1 Sección 4: Propiedad 4.4.2      ¿Cuál es el costo actual del mismo? id_4.4.2_1
```

```
# Muestra exploratoria de respuestas del dataframe de encuestas
df %>% group_by(id_4.3_1, id_4.4.2_1) %>% summarise("TOTAL" = n())
```

```
## # A tibble: 35 x 3
## # Groups:   id_4.3_1 [6]
##   id_4.3_1 id_4.4.2_1 TOTAL
##   <chr>      <dbl> <int>
## 1 Alquilado    3500     1
## 2 Alquilado    4000     1
## 3 Alquilado    4500     1
## 4 Alquilado    5000     4
## 5 Alquilado    5500     1
## 6 Alquilado    6000     3
## 7 Alquilado    6500     1
## 8 Alquilado    7000     2
## 9 Alquilado    7500     1
## 10 Alquilado   8000     4
## # i 25 more rows
```

```
# Selección de datos
df_costo<- df %>%
  select(ORDEN, PROVINCIA, BARRIO, id_4.3_1, id_4.4.2_1)
```

```
# Muestra de datos
#df_costo
```

```
# Muestra de medidas características sobre la distribución de encuestas en barrios según filtro anterior
df_costo %>%
  filter(grepl("Alquilado", id_4.3_1)) %>%
  select(id_4.4.2_1) %>%
  summary()
```

```
## id_4.4.2_1
## Min. : 3500
## 1st Qu.:10000
## Median :14000
## Mean :14028
## 3rd Qu.:17000
## Max. :30000
```

Descripciones graficas de la relación entre variables

Dos variables categóricas

COMPLETAR CON 7.2 y 7.4

- Sección: 7
- Referencia: 7.2
- Pregunta: “¿Qué tipo de tendido eléctrico posee dentro de la vivienda?”
- Respuestas: “Tendido fuera de las paredes o parcialmente fuera de las paredes” “Todo el tendido dentro de las paredes”
- Sección:
- Referencia: 7.4
- Pregunta: “¿Sufrió incendios dentro de su vivienda durante el último año debido a las condiciones de la instalación eléctrica?”
- Respuestas: “Sí” “No”

```
# Muestra Seccion y pregunta del dataframe de encuestas
dh %>% filter(grepl("7.2", REFERENCIA))
```

```
## # A tibble: 1 x 4
## # Groups:   PREGUNTA [1]
## SECCIONES          REFERENCIA PREGUNTA          ID
## <chr>              <chr>      <chr>          <chr>
## 1 "Sección 7: Electricidad\n\n\n\n\n" 7.2      ¿Qué tipo de tendido elé~ id_7~
```

```
# Muestra exploratoria de respuestas del dataframe de encuestas
df %>% group_by(id_7.2_1) %>% summarise("TOTAL" = n())
```

```
## # A tibble: 2 x 2
## id_7.2_1          TOTAL
## <chr>            <int>
## 1 Tendido fuera de las paredes o parcialmente fuera de las paredes 622
## 2 Todo el tendido dentro de las paredes 600
```

```
# Muestra Seccion y pregunta del dataframe de encuestas
dh %>% filter(grepl("7.4", REFERENCIA))
```

```
## # A tibble: 1 x 4
## # Groups:   PREGUNTA [1]
## SECCIONES          REFERENCIA PREGUNTA          ID
## <chr>              <chr>      <chr>          <chr>
## 1 "Sección 7: Electricidad\n\n\n\n\n" 7.4      ¿Sufrió incendios dentro~ id_7~
```

```
# Muestra exploratoria de respuestas del dataframe de encuestas
df %>% group_by(id_7.4_1) %>% summarise("TOTAL" = n())
```

```
## # A tibble: 2 x 2
##   id_7.4_1 TOTAL
##   <chr>      <int>
## 1 No        1145
## 2 Sí         77

# Selección de datos
df_incendios <- df %>%
  select(ORDEN, PROVINCIA, BARRIO, id_7.2_1, id_7.4_1)

# Muestra de datos
#df_incendios
```

Una variable categórica y una variable cuantitativa

COMPETAR CON MOTIVOS.

- Sección: 5 Agua y saneamiento
- Referencia: 5.3 y 5.3.1
- Pregunta: “¿Cómo es la presión del agua?”
- Respuestas: “Buena” “Débil” “Muy débil”
- Sección: 3 Hacinamiento
- Referencia: 3.2
- Pregunta: “¿Cuál es el número MÁXIMO de personas que duermen en estos dormitorios usualmente?”
- Respuestas: De 1 a más de 10

```
# Muestra Seccion y pregunta del dataframe de encuestas
dh %>% filter(grepl("5.3", REFERENCIA))
```

```
## # A tibble: 1 x 4
## # Groups:   PREGUNTA [1]
##   SECCIONES          REFERENCIA PREGUNTA          ID
##   <chr>            <chr>      <chr>          <chr>
## 1 Sección 5: Agua y saneamiento 5.3      ¿Cómo es la presión del agua? id_5.3~
```

```
# Muestra exploratoria de respuestas del dataframe de encuestas
df %>% group_by(id_5.3_1) %>% summarise("TOTAL" = n())
```

```
## # A tibble: 3 x 2
##   id_5.3_1 TOTAL
##   <chr>      <int>
## 1 Buena      576
## 2 Débil      446
## 3 Muy débil  200
```

```
# Muestra Seccion y pregunta del dataframe de encuestas
dh %>% filter(grepl("3.2", REFERENCIA))
```

```
## # A tibble: 1 x 4
## # Groups:   PREGUNTA [1]
##   SECCIONES          REFERENCIA PREGUNTA          ID
##   <chr>            <chr>      <chr>          <chr>
## 1 "Sección 3: Hacinamiento\n" 3.2      ¿Cuál es el número MÁXIMO de per~ id_3~
```

```
# Muestra exploratoria de respuestas del dataframe de encuestas
df %>% group_by(id_3.2_1) %>% summarise("TOTAL" = n())
```

```
## # A tibble: 10 x 2
##   id_3.2_1 TOTAL
##   <dbl> <int>
## 1      1    183
## 2      2    494
## 3      3    269
## 4      4    159
## 5      5     66
## 6      6     27
## 7      7     14
## 8      8      6
## 9      9      3
## 10     10      1
```

```
# Selección de datos
df_agua <- df %>%
  select(ORDEN, PROVINCIA, BARRIO, id_5.3_1, id_3.2_1)

# Muestra de datos
#df_agua
```

Dos variables cuantitativas

1.9. Cantidad de menores en la vivienda 8.4. Cantidad de telefonos/tablets en la vivienda

COMPLETAR

- Sección: 1 Características generales de la composición del hogar
- Referencia: 1.9
- Pregunta: “¿Cuántas personas menores de 18 años hay en la vivienda?”
- Respuestas: De 0 a más de 10
- Sección: 8 Conectividad
- Referencia: 8.4
- Pregunta: “¿Cuántos teléfonos y/o tablets poseen en la vivienda?”
- Respuestas: De 0 a más de 10

```
# Muestra Seccion y pregunta del dataframe de encuestas
dh %>% filter(grepl("1.9", REFERENCIA))
```

```
## # A tibble: 3 x 4
## # Groups:   PREGUNTA [3]
##   SECCIONES                                REFERENCIA PREGUNTA ID
##   <chr>                                <chr>      <chr>   <chr>
## 1 Sección 1: Características generales de la composic~ 1.9      "¿Cuánt~ id_1~
## 2 Sección 11: Ambiente                        11.9.1    "¿De qu~ id_1~
## 3 Sección 11: Ambiente                        11.9.2    "¿Con q~ id_1~
```

```
# Muestra exploratoria de respuestas del dataframe de encuestas
df %>% group_by(id_1.9_1) %>% summarise("TOTAL" = n())
```

```
## # A tibble: 9 x 2
##   id_1.9_1 TOTAL
##   <dbl> <int>
## 1      0    300
## 2      1    276
## 3      2    284
## 4      3    187
## 5      4     93
## 6      5     58
## 7      6     18
## 8      7      5
## 9      9      1

# Muestra Sección y pregunta del dataframe de encuestas
dh %>% filter(grepl("8.4", REFERENCIA))

## # A tibble: 1 x 4
## # Groups:   PREGUNTA [1]
##   SECCIONES                                REFERENCIA PREGUNTA                                ID
##   <chr>                                <chr>          <chr>                                <chr>
## 1 "Sección 8: Conectividad\n\n\n\n" 8.4          ¿Cuántos teléfonos y/o tab~ id_8~

# Muestra exploratoria de respuestas del dataframe de encuestas
df %>% group_by(id_8.4_1) %>% summarise("TOTAL" = n())

## # A tibble: 6 x 2
##   id_8.4_1 TOTAL
##   <chr>      <int>
## 1 0          162
## 2 1          302
## 3 2          371
## 4 3          227
## 5 4          100
## 6 5           60

# Selección de datos
df_tablets <- df %>%
  select(ORDEN, PROVINCIA, BARRIO, id_1.9_1, id_8.4_1)

# Muestra de datos
#df_tablets
```

CREANDO NUEVA VARIABLE 12.1.1.

Utilizando los datos de las columnas 5.1, 6.1 y 7.1, construimos una nueva variable que indica la cantidad de servicios formales que tiene cada hogar.

```
# Función auxiliar para recodificar respuestas
recodificar_respuestas <- function(df, id, respuestas_positivas) {
  variable <- df[[id]]
  respuestas_unicas <- unique(variable)
  # Recodificación según respuestas positivas
  for (i in seq_along(respuestas_unicas)) {
    variable[variable == respuestas_unicas[i]] <-
      ifelse(i %in% respuestas_positivas, "1", "0")
  }
}
```

```

  as.numeric(variable)
}

# id_5.1_1: la segunda respuesta es "A través de una conexión con medidor
# a la red pública, se considera positiva. El resto, se considera negativa.
res_5.1_1 <- recodificar_respuestas(df, "id_5.1_1", respuestas_positivas = 2)

# id_6.1_1: las respuestas N/A se consideran negativas.
res_6.1_1 <- df[["id_6.1_1"]]
res_6.1_1 <- ifelse(is.na(res_6.1_1), 0, ifelse(res_6.1_1 == unique(res_6.1_1)[1], 1, 0))
res_6.1_1 <- as.numeric(res_6.1_1)

# id_7.1_1: La primera respuesta es "Conexión a través de un medidor a la
# red eléctrica", se considera positiva. El resto, se considera negativa.
res_7.1_1 <- recodificar_respuestas(df, "id_7.1_1", respuestas_positivas = 1)

# Creacion de la variable 12.1_1: Suma total por fila de las anteriores
total_encuestados <- 1222
res_12.1_1 <- rowSums(cbind(res_5.1_1, res_6.1_1, res_7.1_1))

# TABLA RESUMEN ---
total_12.1_1 <- table(res_12.1_1)
frec_12.1_1 <- round(total_12.1_1 / total_encuestados, 2)
cumsum_12.1_1 <- cumsum(frec_12.1_1)
table_12.1_1 <- cbind(total_12.1_1, frec_12.1_1, cumsum_12.1_1)

# Muestra de datos
table_12.1_1

##   total_12.1_1 frec_12.1_1 cumsum_12.1_1
## 0             575        0.47          0.47
## 1             354        0.29          0.76
## 2             256        0.21          0.97
## 3              37        0.03          1.00

```